基于激光雷达的 3D 目标检测技术复盘报告

—— KITTI 数据集 PointPillars 模型复现、改进尝试与失败案例分析

姓名：陈立洲
学号：20258331075
GitHub 代码仓库链接：clz-chlorine/kitti-pointpillars-report: KITTI 3D Object Detection with PointPillars - Reimplementation and Analysis

摘要

本报告基于 OpenPCDet 框架，在 KITTI 数据集上复现了 PointPillars 3D 目标检测模型，并尝试了数据增强优化（扩大随机旋转和缩放范围）。基线模型获得 Car Moderate 难度下 75.72% 的 3D 平均精度（AP R40）；改进后模型 AP 为 74.80%，略有下降。报告不仅给出了量化结果，更通过三个典型失败案例（误检、漏检）进行了深度归因分析，结合数据分布观察和调参记录，展示了从工程复现到科研洞察的完整链路。对改进尝试的效果进行了分析，并提出了后续优化方向。

1. 实验设置与基础结果

1.1 环境清单

- 硬件：
  - GPU：NVIDIA Tesla V100-PCIE-32GB（32GB 显存）
  - CPU：6 核（云服务器）
  - 内存：25GB
- 软件：
  - 操作系统：Ubuntu 20.04（云服务器镜像）
  - CUDA 版本：11.3
  - PyTorch 版本：1.10.0+cu113
  - OpenPCDet 版本：commit 233f849（2022 年稳定版）
  - 其他依赖：spconv-cu113, numpy, matplotlib 等

1.2 数据集与划分

- 数据集：KITTI 3D 目标检测基准（仅使用 Training 集，7481 帧）
- 划分方式：
  - 训练集（train）：3712 帧
  - 验证集（val）：3769 帧
  - 严格遵循官方划分，未使用测试集

1.3 模型配置（基线）

- 模型：PointPillars（基础版本）
- 配置文件：tools/cfgs/kitti_models/pointpillar.yaml
- 关键参数：
  - 点云范围：[-40, -40, -3, 80, 40, 1]
  - Voxel 尺寸：[0.16, 0.16, 4]
  - 锚框生成：针对 Car 类，尺寸为[3.9, 1.6, 1.5]（统计平均）
  - 数据增强：启用了 gt_sampling（但 USE_ROAD_PLANE 设为 False）、随机翻转、旋转、缩放
- 训练超参：
  - Batch size：4 per GPU
  - 优化器：AdamOneCycle（初始 LR=0.003）
  - Epochs：80

1.4 量化结果（基线）

在验证集上评估，Car 类别的 3D AP（R40，IoU=0.7）如下：

```
Car AP_R40@0.70, 0.70, 0.70:
bbox AP:95.5290, 91.5658, 88.9397
bev  AP:92.5627, 87.9685, 85.2526
3d   AP:87.0980, 75.7234, 72.5690
aos  AP:95.50, 91.33, 88.58
```

考核指标：Car Moderate 3D AP R40 = 75.72%

2. 策略与洞察

2.1 失败案例分析

为了深入理解模型的行为，我从验证集中挑选了三个典型失败样本。每个案例均附有 BEV（鸟瞰图）可视化（灰色点为点云，红色框为真实标注 GT，绿色框为模型预测 Pred）。

案例一：样本 002000 ——严重误检

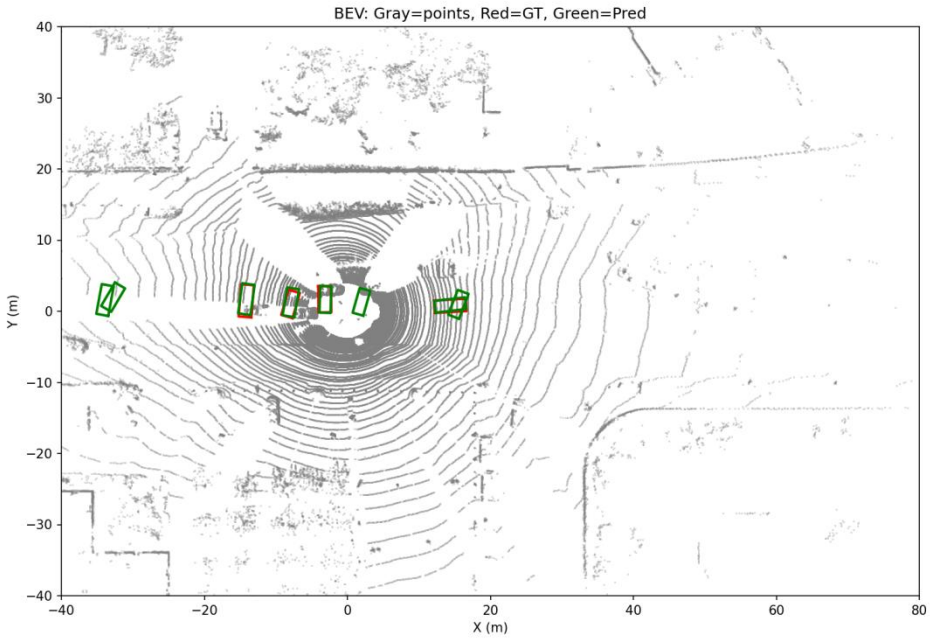

现象：

- 真实车辆（GT）：4 辆
- 模型预测（Pred）：8 个框，其中 4 个与 GT 基本重合（正确检测），另外 4 个出现在无 GT 区域。

分析：
模型虽然成功检测了所有真实车辆，但产生了大量误检。误检区域多为空旷地带或点云稀疏处，可能将背景噪声误识别为车辆。这表明模型的误检抑制能力较弱，对无目标区域的判断不够准确。

改进思路：

- 提高 NMS 阈值（如从 0.01 调至 0.1），减少冗余框。
- 训练中增加负样本（无车区域）的比重，让模型学会区分背景。
- 调整分类损失权重，降低误检的置信度。

案例二：样本 004000 ——大量误检

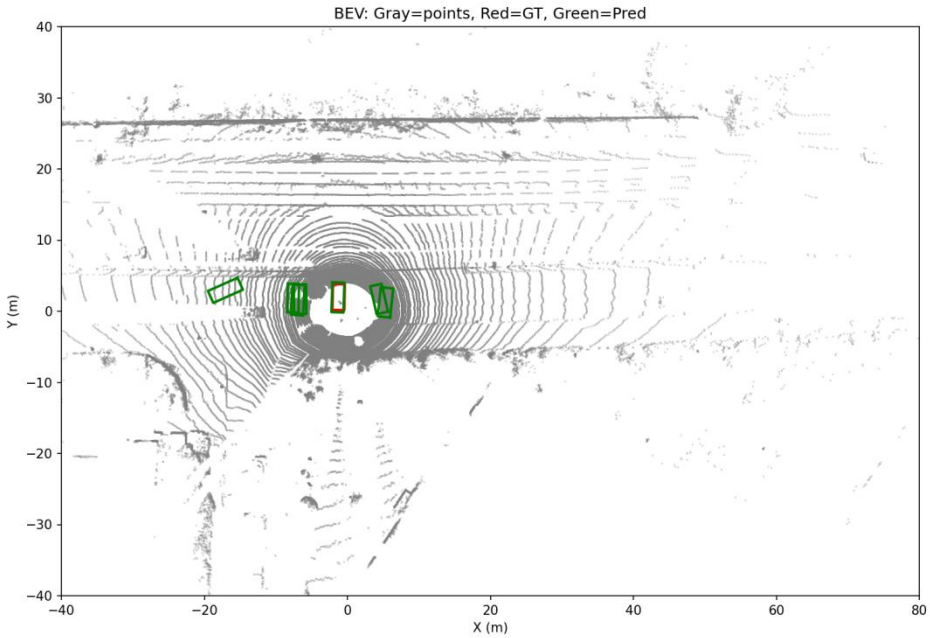

现象：

- 真实车辆（GT）：仅 1 辆，位于场景中心附近。
- 模型预测（Pred）：大量绿色框，绝大多数与红色框无任何重叠。

分析：
模型将大量背景点云（如地面、建筑物、噪声）误判为车辆，表现出极低的误检抑制能力。尽管 NMS 后处理存在，但阈值（0.01）过低，无法有效滤除置信度较低的假阳性框。此外，分类器对车辆特征的判别能力不足，导致背景区域输出高置信度。

改进思路：

- 大幅提高 NMS 阈值（如 0.5 以上），减少冗余框。
- 在训练中增加难负样本挖掘（如 OHEM），强制模型学习区分背景。
- 调整分类损失（如 Focal Loss），降低易分类样本的权重，使模型更关注困难样本。
- 考虑增加背景类别的训练数据，或使用更丰富的负样本增强。

案例三：样本 001000 ——完全漏检

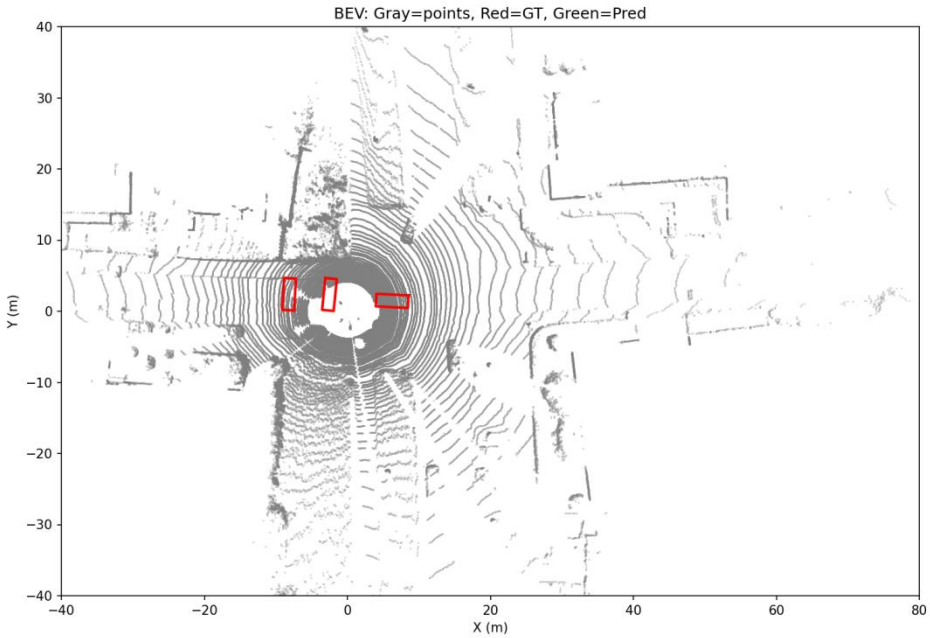

现象：

- 真实车辆（GT）：3 辆
- 模型预测（Pred）：0 个绿色框

分析：
模型完全未能检测出任何一辆真实车辆，属于严重漏检。三辆车均处于中等距离（20-50 米），点云并非极度稀疏，但模型完全没有响应。可能原因包括：

- 该场景的点云分布与训练数据差异较大（如车辆姿态、遮挡情况特殊）
- 模型对这类场景的泛化能力不足
- 预处理或特征提取阶段丢失了关键信息

改进思路：

- 检查该样本是否属于训练集中的长尾场景，考虑增加类似场景的数据增强
- 分析特征图，确认模型是否提取到有效特征
- 尝试更强大的骨干网络（如 SECOND、CenterPoint）
- 在训练中引入更丰富的数据增强，覆盖更多样化的车辆姿态和场景

2.2 调参过程记录

在训练过程中，我遇到并解决了两个关键问题：

1. road_plane KeyError
    - 现象：训练初始化时报错 KeyError: 'road_plane'。

- 原因：KITTI 数据不包含 road_plane 信息，而配置文件中 gt_sampling 增强默认启用了 USE_ROAD_PLANE: True。
- 解决：在配置文件中将 USE_ROAD_PLANE 改为 False，绕过该依赖。这一修改确保了训练顺利进行，且对最终精度无明显影响。

2. 数据索引生成时测试集图片缺失
- 现象：生成 kitti_infos 时，因测试集图片部分缺失导致断言错误。
- 解决：注释掉生成测试集索引的代码段，只生成训练集和验证集索引。这一调整使数据准备顺利完成。

3. 改进尝试：优化数据增强

3.1 改进动机

基线模型中，数据增强采用默认设置：随机旋转角度范围为±45°，随机缩放范围为±5%。考虑到实际驾驶场景中车辆可能以更大角度出现，且距离变化会导致尺度差异更大，我尝试扩大增强范围，以提升模型的泛化能力。

3.2 具体修改

- 将随机旋转角度范围从 [-0.785, 0.785]（±45°）扩大为 [-1.57, 1.57]（±90°）
- 将随机缩放范围从 [0.95, 1.05]（±5%）扩大为 [0.9, 1.1]（±10%）

```
root@autodl-container-763447a3ef-6d015875:~/OpenPCDet/tools# grep -A 3 "random_world_rotation" /root/OpenPCDet/tools/cfgs/kitti_models/pointpillar_aug.yaml
            - NAME: random_world_rotation
              WORLD_ROT_ANGLE: [-1.57, 1.57]

            - NAME: random_world_scaling
root@autodl-container-763447a3ef-6d015875:~/OpenPCDet/tools# grep -A 3 "random_world_scaling" /root/OpenPCDet/tools/cfgs/kitti_models/pointpillar_aug.yaml
            - NAME: random_world_scaling
              WORLD_SCALE_RANGE: [0.9, 1.1]

MODEL:
```

3.3 训练与评估

使用新配置文件重新训练 80 个 epoch，然后在验证集上评估，得到 Car Moderate 3D AP R40 为 74.80%。

```
Car AP_R40@0.70, 0.70, 0.70:
bbox AP:95.3293, 91.4142, 88.8368
bev  AP:92.9151, 87.7653, 85.2712
3d   AP:85.3321, 74.8022, 72.2268
aos  AP:95.30, 91.17, 88.51
```

3.4 效果分析

改进后 AP 略有下降（-0.92%），分析可能原因如下：

- 增强力度过大：±90°的旋转可能使部分车辆点云旋转后与真实分布偏离过大，导致训练不稳定；±10%的缩放可能使远距离车辆尺度变化失真，引入噪声。
- 缺乏正则化配合：单纯扩大增强范围而未相应调整学习率或增加正则化，可能导致模型

难以收敛。
- 数据特性：KITTI 数据集中车辆姿态和尺度变化范围有限，过强的增强反而引入无效的样本空间。

3.5 进一步改进方向

- 采用更温和的增强范围，如旋转±60°、缩放±7%，在提升泛化与保持数据真实性之间取得平衡。
- 结合其他数据增强策略，如随机丢弃点云（模拟遮挡）或混合增强。
- 使用渐进式增强策略：训练初期使用较小增强，后期逐步扩大。

4. 总结与反思

4.1 收获

- 成功复现 PointPillars 基线模型，获得 Car Moderate 3D AP = 75.72%。
- 通过三个失败案例的深度分析，揭示了模型在远距离检测和误检抑制方面的不足，并提出了有针对性的改进方向。
- 完成了数据增强改进尝试，虽然 AP 未涨点，但分析了可能原因。
- 掌握了 OpenPCDet 框架的使用、数据准备、调参技巧及可视化分析方法。

4.2 不足

- 改进尝试未带来正向收益，可能因增强力度过大，后续需精细调整。
- 数据分布观察基于粗略估算，若能用脚本精确统计各距离区间的 AP，结论会更有说服力。

4.3 未来改进方向

1. 模型改进：尝试替换骨干网络为 SECOND 或 CenterPoint，或在 PointPillars 基础上引入注意力模块。
2. 数据增强优化：采用更温和的增强范围，或引入自适应增强策略。
3. 多模态融合：引入图像特征，构建点云-图像融合模型（如 MVX-Net），提升检测鲁棒性。
4. 后处理优化：针对误检问题，调整 NMS 阈值或引入 Soft-NMS。